



EDA Google Sheets

Objetivo del proyecto

Descripción de datos

Tratamiento y Limpieza de datos

Featured Engineering

Análisis Descriptivo

Planteamiento de la hipótesis

Análisis estadístico Dashboard

Segmentación por género

Género: Male (Masculino)

Género: Female (Femenino)

Conclusiones

Segmentación por especialidad

EEE (Electrical and Electronics Engineering)

ECE (Electronics and Computing Engineering)

IT (Information Technologies)

Conclusiones

Segmentación por conocimientos técnicos

Conocimientos en Java

Conocimientos de Python

Conocimientos de SQL

Conocimientos de Web Development

Conocimientos de Data Science

Conclusiones

Segmentación por pertenencia a clubes

Pertenencia al grupo de literatura

Pertenencia al grupo de robótica

Conclusiones

 Resumen ejecutivo

Objetivo del proyecto

Realizar un análisis exploratorio de un conjunto de datos de elección propia y reflejar el resultado en un dashboard.

▼ Requisitos

- Transformación y limpieza de los datos.
- Análisis descriptivo de los datos.
- Análisis estadístico de los datos.
- Dashboard Operativo.
- Informe explicativo del análisis.

▼ Herramientas:

- Google Sheets
- Excel

▼ Datos:

Los datos pueden descargarse de cualquiera de los siguientes sitios webs, y deben tener una extensión mínima de 2000 filas y 10 columnas.

- <https://www.kaggle.com/>
- <https://datasearch.research.google.com/>
- <https://registry.opendata.aws/>
- <https://data.gov/>
- https://data.europa.eu/data/datasets?is_hvd=true&locale=en
- <https://www.ine.es/>



Descripción de datos

El dataset se ha descargado de

<https://www.kaggle.com/datasets/rakeshkapilavai/engineering-student-journey>

y la estructura es la siguiente:

| Columna | Significado | Data type |
|---------------------|---|-------------|
| Student ID | Identificador del alumno | String |
| Name | Nombre del alumno | String |
| Age | Edad del alumno | Integer |
| Gender | Género del estudiante | String |
| Branch | Rama de sus estudios | Categorical |
| Average GPA | Nota media de los semestres | Float |
| Backlogs | Número de cursos suspensos | Integer |
| Attendance | Porcentaje de clases a las que asiste | Float |
| Clubs | Clubs extracurriculares | String |
| Skills | Habilidades técnicas | String |
| Internship Done | Indicador de prácticas (Yes/No) | Categorical |
| Internship Domain | Dominio de las prácticas | Categorical |
| Placement Status | Indicador de si encuentra empleo (Yes/No) | Categorical |
| Placement Domain | Dominio del empleo | Categorical |
| CTC (LPA) | Coste Anual de la compañía en Lakhs | Flot |
| Alumni Path | Carrera post graduación | Categorical |
| Sem1 GPA - Sem8 GPA | GPA de cada semestre (0-10) | Float |

El dataset original cumple con el mínimo de 2000 filas que se requiere en el proyecto, así como con las columnas, ya que tenemos 24 filas diferentes.

Tratamiento y Limpieza de datos

En la tabla anterior se ha indicado qué significado tiene cada columna de datos de nuestro dataset, así como el tipo de dato que deberían tener dichas columnas. Sin embargo, esto no implica que los datos del dataset ya tengan dicho tipo de datos, ni tampoco implica que los datos sean únicos o que no contenga datos nulos. Por tanto, una vez conocidos los datos, el siguiente paso para nuestro EDA será el de asegurar que no existen datos nulos y si existen,

decidir que valor imputar a estos, limpiar los duplicados, corregir el tipo de dato, y si hiciera falta, corregir los separadores de decimales (que podrían generar errores a la hora de dar formato a los datos).

- **Student ID:** esta columna, como hemos dicho representa el ID único de cada uno de los alumnos, por lo que debemos eliminar los duplicados, si existen, y los nulos, ya que no debe generarse un registro de alumnos sin ID único.
Como se muestra en la imagen de abajo, no se tienen duplicados pero si que existe algún dato vacío que debe eliminarse.
- **Name:** los nombres deben ser tipo string y si que pueden repetirse. Como el nombre no es algo relevante para nuestro análisis, en caso de tener algún nulo, lo imputaremos como 'Desconocido'.
- **Age:** la edad si que es un dato relevante para nuestro análisis. Este dato es un dato numérico, y deberá ser tipo integer, ya que la edad la contamos de manera discreta y no continua. En caso de que se tuvieran valores nulos, se comprobará la distribución de edad para imputar los valores.
Al estar utilizando una configuración de google sheets en español, el separador de decimales es la coma, por lo que antes de poder convertir los datos de tipo string a tipo numérico debemos cambiar el separador.
Una vez realizada la transformación, con los datos con formato numérico puede observarse que no existen valores nulos y que la edad está comprendida en un intervalo de entre 18 y 23 años.
- **Gender:** la columna de género deberá ser tipo categórico, que en google sheets se comporta como un string. Los géneros que vamos a utilizar en este caso serán Male/Female y en caso de posibles valores nulos se imputará N/A. Sin embargo, tampoco se encuentra ningún valor no especificado, por lo que no es necesario realizar ningún tipo de transformación de estos datos.
- **Branch:** la rama de la educación también es de tipo categórico y por tanto, al igual que para el género, vamos a tratarlo como un string.
Como no existen valores nulos tampoco es necesario realizar ningún tipo de operación sobre los datos de esta columna.
- **Average GPA:** la calificación media de los alumnos se mida en formato numérico, por lo que debemos garantizar que el separador decimal es el correcto antes de transformar estos datos en numéricos.
Una vez corregidos los separadores podemos observar cómo se

distribuyen estos datos. En este caso no observamos ningún valor nulo, pero podría haberse imputado tanto la media como la mediana, ya que no parece tener una distribución sesgada.

- **Backlogs:** para el caso de los cursos suspensos, los datos deben ser numéricos enteros, por lo que debemos asegurar que los datos originales en formato float tienen como separador decimal comas en lugar de puntos. Del mismo modo que las columnas anteriores, no tenemos ningún nulo, por lo que no es necesario realizar ningún tipo de procesamiento de estos datos.
- **Attendance (%):** el porcentaje de asistencia a clase debe ser de tipo float o entero si se quisiera redondear el valor. En este caso no vamos a redondear y lo vamos a dejar como float, por lo que se deberá comprobar nuevamente el separador antes de convertir en numérico.

En estos datos no será necesario imputar ningún valor ya que tampoco encontramos nulos.

- **Clubs:** en la columna de pertenencia a clubs los datos deben ser de tipo string, por lo que en este caso no se debe hacer ningún cambio en el formato de los datos.
Tampoco existen nulos en esta columna y tiene muchos valores únicos, ya que cada combinación de clubes diferentes podría dar lugar a una categoría diferente.
- **Skills:** al igual que para el caso de los clubes, los datos deben ser de tipo string y por tanto, en este caso tampoco se debe hacer ninguna transformación en el tipo de dato.
Esta columna tampoco presenta valores nulos, y tiene una gran cantidad de valores únicos debido a la gran cantidad de combinaciones que podría existir.
- **Internship Done:** este dato es de tipo categórico, que en Google Sheets se comporta como un string, y sus valores deben ser 'Yes' o 'No'.
Como no existen valores nulos en esta columna, no es necesario realizar ninguna transformación.
- **Internship Domain:** la especialidad o dominio de las prácticas se debe indicar con texto, por lo que no se necesita ninguna transformación del formato de los datos.
En este caso si que existen filas nulas, por lo que en este caso se imputa una nueva categoría 'Not Specified'.
Aquí ya se observa como la mayoría de los alumnos no especifican el tipo

de prácticas, que posteriormente podremos ver si solo tiene lugar en aquellos casos en los que no se han realizado las prácticas.

- **Placement Status:** el indicador de trabajo colocación también se trata de un dato categórico, por lo que al encontrarse originalmente como texto no es necesario realizar ningún tipo de transformación sobre esta columna. Al no tener valores nulos tampoco es necesario imputar ninguna nueva categoría.
- **Placement Domain:** el dominio de la colocación/trabajo también es un tipo categórico, y al ser originalmente un dato tipo string no es necesario realizar ninguna transformación.
En el caso de los nulos de esta columna se imputa la categoría 'Not Specified', que al igual que vimos con las prácticas, tiene una alta frecuencia y se deberá comprobar posteriormente si se debe a tener un **Placement Status** de 'Not Placed'.
- **CTC (LPA):** el coste a la compañía está medido en Lakhs, unidad monetaria, por lo que podrá tener decimales y por tanto, ser un float. En esta columna se debe transformar el separador de decimales antes de cambiar el tipo de dato.
No existen nulos por lo que no será necesario realizar ninguna imputación.
- **Alumni Path:** esta columna es de tipo categórico y los datos originales están en tipo string, así que no se necesita transformar nada.
Para el caso de los valores nulos se imputa la categoría 'Not Available'.
- **Sem1 GPA - Sem8 GPA:** estas columnas representan las notas medias por semestre, por lo que sus datos son de tipo float. Para asegurar el tipo numérico en esta columna se deben verificar los separadores decimales.
En este caso tampoco existen valores nulos, por lo que no es necesario realizar ninguna acción extra.

Featured Engineering

En esta sección se detalla como se han generado nuevas columnas que puede proporcionar información más precisa del conjunto de datos que las que se tenían originalmente.

En esta etapa del análisis se han generado nuevas columnas:

- **Number of clubs:** es el número de clubs a los que pertenece el alumno.

- **Club Flag:** es un indicador de los clubes a los que pertenece el alumno. Se tienen tantos clubs como diferentes clubs haya en la columna **Clubs**. Ejemplos: Literary Society, Robotics, etc.
- **Number of Skills:** es el número de habilidades técnicas que tienen los estudiantes.
- **Hability Flag:** es un indicador de las habilidades extraídas para cada alumno. Se tienen tantas columnas de hability flags como habilidades diferentes haya. Su valor puede ser 1, si el alumno posee esa habilidad, o 0 si no la posee. Ejemplos: C++, Web Development, etc.

Para conocer las diferentes flags, se ha utilizado la siguiente línea de código:

```
=TEXTJOIN(", "; VERDADERO;  
UNIQUE(ESPACIOS(FLATTEN(SPLIT(I2:I2000; ","))))
```

Para asignar el valor de 0/1 a cada una de las flags se ha utilizado la siguiente fórmula, que reconoce en la columna Skills o Clubs y asigna el valor:

```
=SI(REGEXMATCH(I2;"(?i)literary society");1;0)
```

Análisis Descriptivo

Una vez conocidas transformados los datos y conocidas las distribuciones de cada columna de datos, vamos pasar a realizar un análisis descriptivo, para poder extraer una conclusión de las relaciones entre las variables y poder plasmarlo en el dashboard.

Para esto, vamos a generar tablas dinámicas que relacionen las variables con el **Placement Status (Empleados vs No Empleados)**, esto es, la empleabilidad de los estudiantes en empresas, que es el objeto del análisis.

En primer lugar se debe conocer que porcentaje de empleabilidad existe entre todos los alumnos.


Tasa de empleabilidad




Aquí ya podemos ver como prácticamente existe la misma cantidad de alumnos empleados que de no empleados.

Lo siguiente será realizar un análisis entre los datos básicos de los estudiantes y su empleabilidad. Estos datos son la edad, el género y la especialidad de los estudios.


Tasa de empleabilidad por edad



Tasa de empleabilidad por género



Tasa de empleabilidad por especialidad




De las gráficas anteriores se puede observar como las distribuciones de empleados y desempleados son muy similares, pero sacarse algunas conclusiones:


- La tasa de empleabilidad entre hombres y mujeres es prácticamente igual, pero es ligeramente mayor para el caso de los hombres.
- Los alumnos que mayor empleabilidad tienen son los de 18 y 23 años.
- Las especialidades con mayor empleabilidad son **EEE** (Electrical and Electronics Engineering), **ECE** (Electronics and Communication Engineering) y **IT** (Information Technologies).





El siguiente paso será realizar el mismo análisis con datos de asistencia y rendimiento de los estudiantes, por lo que vamos a relacionar la empleabilidad con la asistencia, la nota media y los cursos repetidos.

Tasa de empleabilidad por suspensos



Tasa de empleabilidad por suspensos





De los gráficos anteriores se pueden extraer las siguientes conclusiones:


- Parece que el número de suspensos no guarda relación con la empleabilidad, pues puede observarse que alumnos con mayor tasa de suspensos, tienen una mayor empleabilidad. Sin embargo, no puede emitirse esta conclusión con gran precisión pues el número de alumnos con asignaturas suspensas es muy inferior al número de alumnos con pocas suspensas. Además, podemos ver cómo el porcentaje de empleabilidad en aquellos casos donde tenemos un volumen alto de alumnos, es muy similar.
- La empleabilidad parece ser mayor cuanto mayor es la asistencia a clase, con la excepción de alumnos que han ido entre el 90 y el 95% del tiempo a clase.
- Por lo general, a medida que aumenta la nota del alumno, su empleabilidad mejora, con la excepción de aquellos alumnos entre el 7.5 y 7.75.

Estos datos, se podrán filtrar posteriormente para dar información más precisa.







Las siguientes variables cuya relación con la empleabilidad se va a analizar son la pertenencia a los clubes y las habilidades técnicas de los estudiantes, así como las columnas derivadas de estas.

Pertenencia a clubes

En primer lugar se ha comparado la empleabilidad en función del número de clubes a los que pertenecen los alumnos.




En este gráfico puede observarse que los alumnos que pertenecen a 3 clubes tienen mayor tasa de empleabilidad. Sin embargo, a continuación se muestra la tasa de empleabilidad de los alumnos de diferentes clubes.





Corroborando los datos de la gráfica anterior, se ve como la pertenencia a cualquiera de los clubes da lugar a una tasa de empleabilidad ligeramente superior al 50%. Sin embargo, se ve una clara mayor empleabilidad en aquellos alumnos que pertenecen a los clubes de robótica y de literatura.




Habilidades técnicas

Primero, al igual que con la pertenencia a los clubes, se va a comparar la empleabilidad en función del número de habilidades técnicas que poseen los estudiantes.



Se puede ver como los alumnos con mayor número de habilidades técnicas son los que presentan una mayor empleabilidad. A continuación se muestra la relación de la empleabilidad con cada una de las habilidades técnicas.






Puede concluirse que tener cualquiera de las habilidades técnicas, a excepción de C++ supone una mejora de la empleabilidad de los alumnos, siendo Java la habilidad técnica que proporciona una mayor tasa de empleabilidad, mientras que en el caso del resto de habilidades técnicas la empleabilidad es prácticamente igual.


Finalmente, vamos a analizar cuál es la tasa de empleabilidad en función de las prácticas realizadas por los alumnos, así como la carrera profesional y el salario de estos.

Prácticas profesionales



Los alumnos que se dedican en sus prácticas a la consultoría, software o Ingeniería son los que menor tasa de empleabilidad tienen, a diferencia de los que se dedican a la enseñanza, investigación y la industria de Hardware.

Carrera profesional



Se puede apreciar como los alumnos empleados tienen preferencia por la investigación, seguidos de la formación de startup, estudios superiores y ser asalariados.

Salarios



En la gráfica se puede observar como se distribuyen los salarios de los alumnos. A simple vista es imposible predecir qué alumnos son los que recibirán un mayor salario, ni qué características tendrían.

A continuación se muestra un dashboard con el que se podrán estudiar las relaciones cruzadas y con el que se van a dar las conclusiones del análisis, tratando de confirmar o rechazar la hipótesis.

Planteamiento de la hipótesis

La empleabilidad de los estudiantes de ingeniería está principalmente determinada por una combinación estratégica de tres factores clave, que tienen mayor peso que el rendimiento académico tradicional.

- **Especialización técnica.** Especialmente en ramas como EEE, ECE e IT.
- **Habilidades técnicas demandadas** (Java, Python, SQL, Web Development y Data Science).
- **Participación extracurricular.**

Además se aprecian brechas significativas diferenciadas según el ámbito y la especialidad. Así mismo, se observa mayor impacto en la empleabilidad por el conocimiento técnico que por el hecho de pertenecer a un grupo social, mientras que el rendimiento académico clásico (nota, asistencia o suspensos) tiene una menor correlación con la empleabilidad.

Análisis estadístico Dashboard

El análisis estadístico de la relación entre las diferentes variables lo vamos a realizar a través del siguiente dashboard.



En el dashboard de la imagen se pueden diferenciar 4 áreas

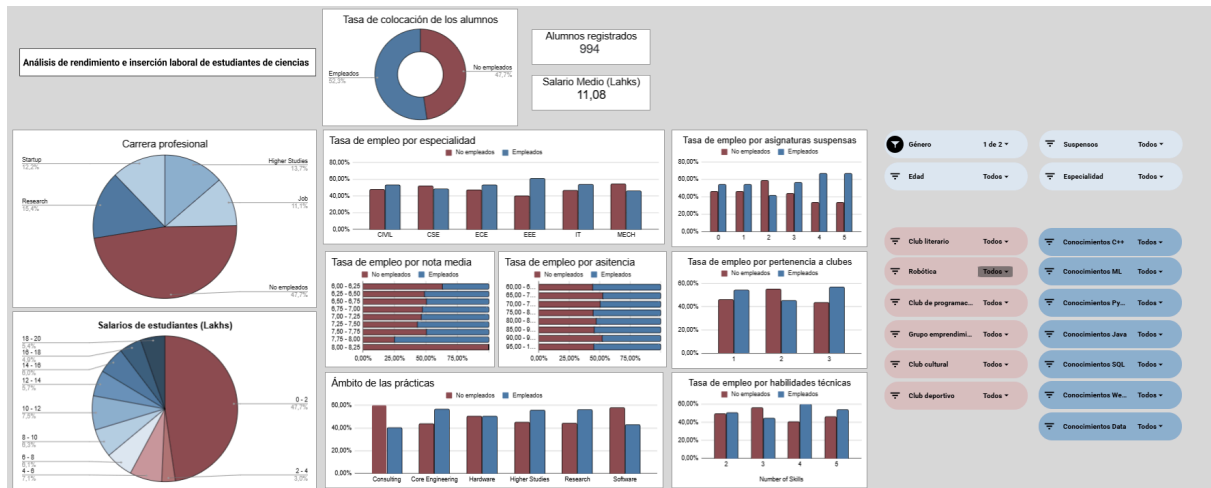
- Registro de alumnos y salario medio
- Distribución de las salidas profesionales y los salarios
- Distribución de los alumnos en función de las variables

- Filtros

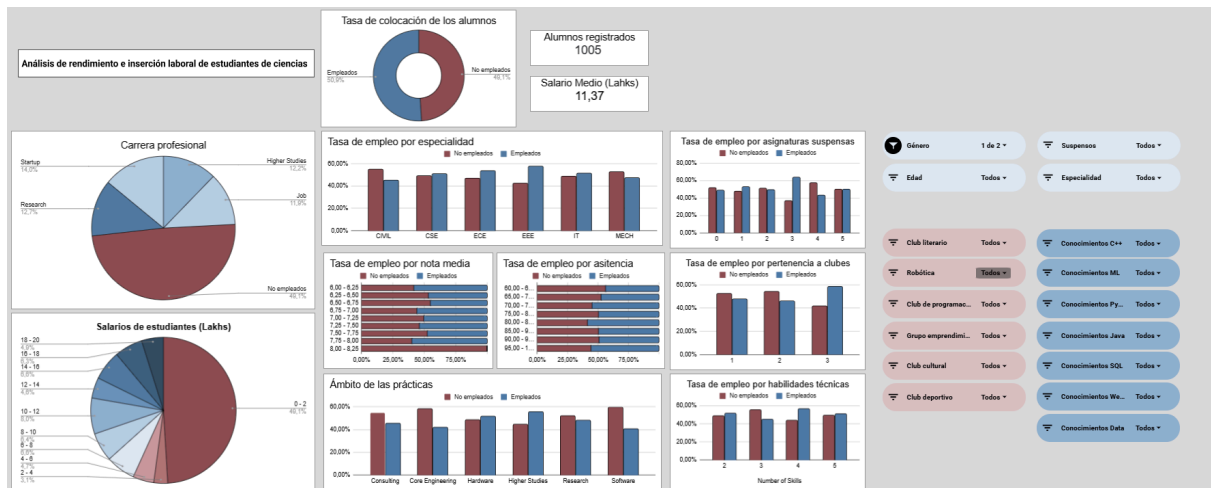
Haciendo uso de este dashboard se va a analizar el conjunto de datos para dar conclusiones en base al análisis estadístico anteriore.

Segmentación por género

Género: Male (Masculino)



Género: Female (Femenino)



Conclusiones

- En el caso del género masculino, el porcentaje de empleabilidad es ligeramente superior 52.3% frente a 50.9%.
- El salario medio femenino es mayor que el masculino, sin embargo, son los alumnos masculinos los que tienen un mayor porcentaje de individuos

dentro del rango más alto del salario.

- El género femenino se decanta más por las startups y el masculino por la investigación, a pesar de que en el conjunto global aparezca una mayor preferencia por la investigación.
- En cuanto a la tasa de empleabilidad por especialidad, no parece haber diferencias significativas entre géneros, ya que ambos siguen la misma tendencia que se ve en el global.
- El género masculino tiene mayor empleabilidad que el femenino cuando se realizan prácticas de Core Engineering o Investigación, mientras que en el resto siguen una distribución similar, excepto en Hardware donde existe mayor empleabilidad para el género femenino.
- En cuanto a la relación de las asignaturas suspensas y la empleabilidad, al género femenino parecen penalizar más las asignaturas suspensas.
- El resto de variables presentan una distribución similar.

Segmentación por especialidad

En base a lo que se apreciaba en el análisis estadístico, se analizan las relaciones para aquellos alumnos que han estudiado EEE, ECE e IT, ya que son aquellas que tienen una mayor tasa de empleabilidad.

EEE (Electrical and Electronics Engineering)



ECE (Electronics and Computing Engineering)



IT (Information Technologies)



Conclusiones

- El salario medio más alto corresponde a aquellos alumnos que han estudiado ECE, el salario de los estudiantes de EEE es ligeramente superior a la media de los estudiantes empleados, y los que estudian IT tienen un salario por debajo de la media, a pesar de tener una mayor empleabilidad que otras especialidades.
- Los estudiantes de EEE prefieren seguir una carrera profesional en la investigación y las startups, y los de ECE e IT prefieren educación.
- En cuanto a las prácticas:
 - Los alumnos de EEE que realizan prácticas en Investigación, Hardware y educación (estudios superiores) tienen una mayor tasa de empleabilidad que los que realizan prácticas en otro ámbito.

- Los alumnos de ECE que realizan prácticas en estudios superiores tienen mayor tasa de empleabilidad y los que las realizan en Hardware tienen una menor empleabilidad. Con el resto de ámbitos de las prácticas tienen una tendencia similar a la general.
- Los alumnos de IT que realizan prácticas en Core Engineering tienen una muy alta empleabilidad, a diferencia de la tendencia general, y los que realizan las prácticas en hardware tienen una empleabilidad muy baja.
- En cuanto a las habilidades técnicas, se puede observar como en EEE e IT aquellos alumnos con mayor cantidad de habilidades tienen una empleabilidad mayor, superior a la tendencia general.
- No se observa ninguna correlación clara entre las notas medias o la asistencia y la empleabilidad.

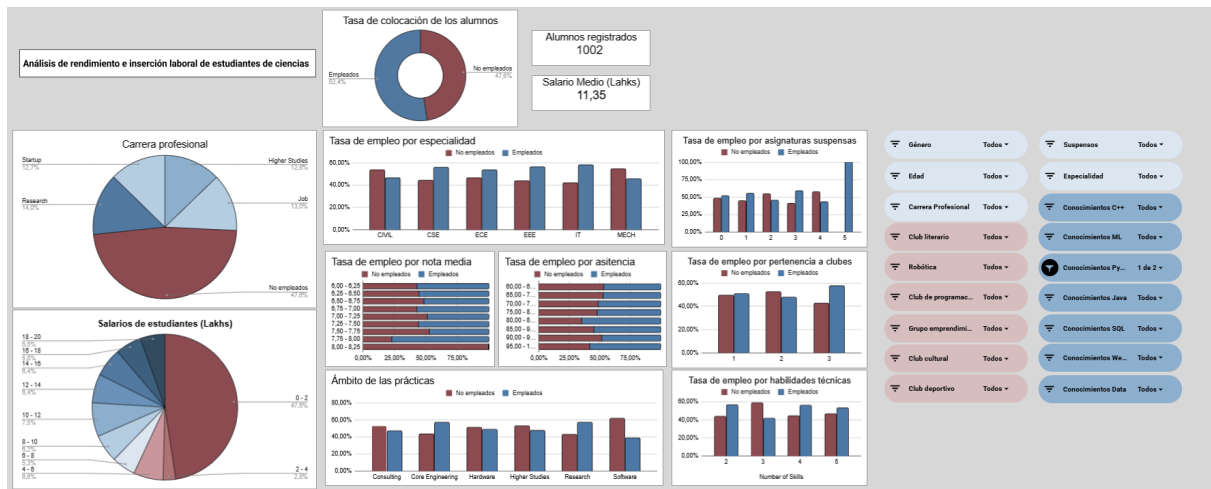
Segmentación por conocimientos técnicos

Se puede observar como existe una clara relación entre la empleabilidad y el ámbito de las prácticas, por lo que es probable que exista algún tipo de relación entre los conocimientos que tienen los alumnos y la empleabilidad, por lo que se analiza a continuación como influye cada habilidad técnica en la tasa de empleo. Al ser Java, SQL, Python, Web Development y Data Science las habilidades que mayor empleabilidad tienen, se van a comparar estas y no las otras dos

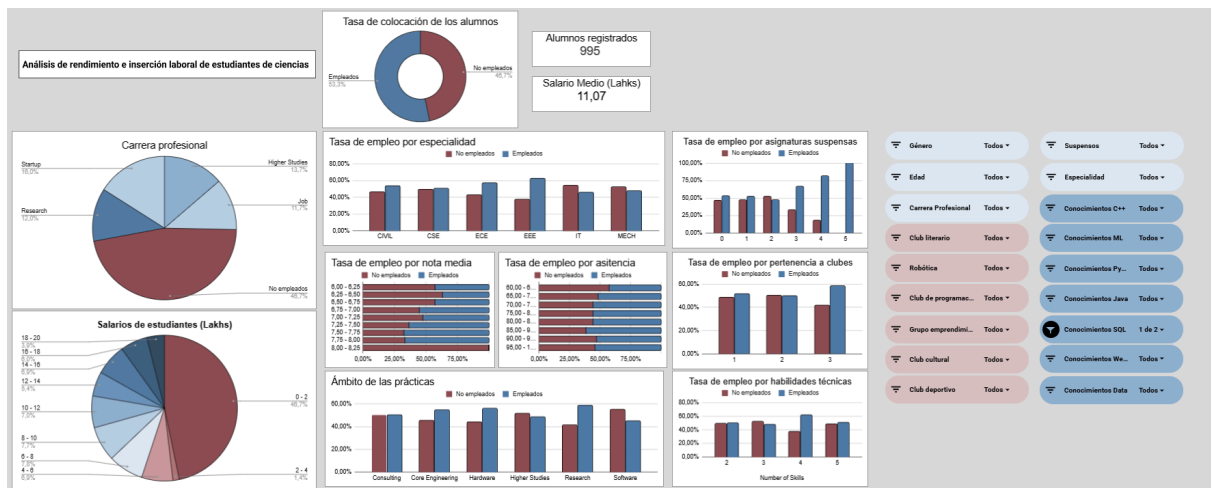
Conocimientos en Java



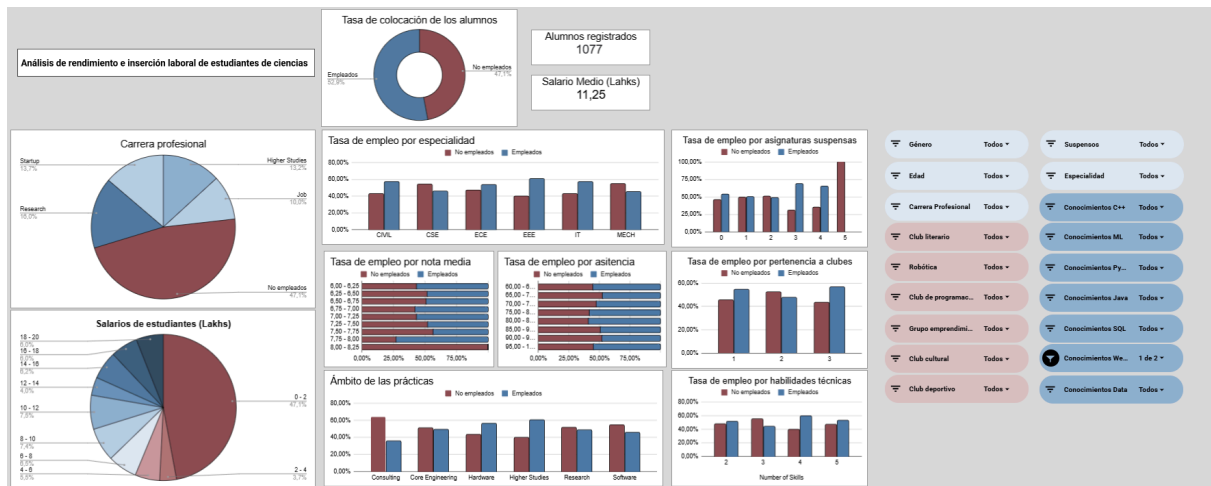
Conocimientos de Python



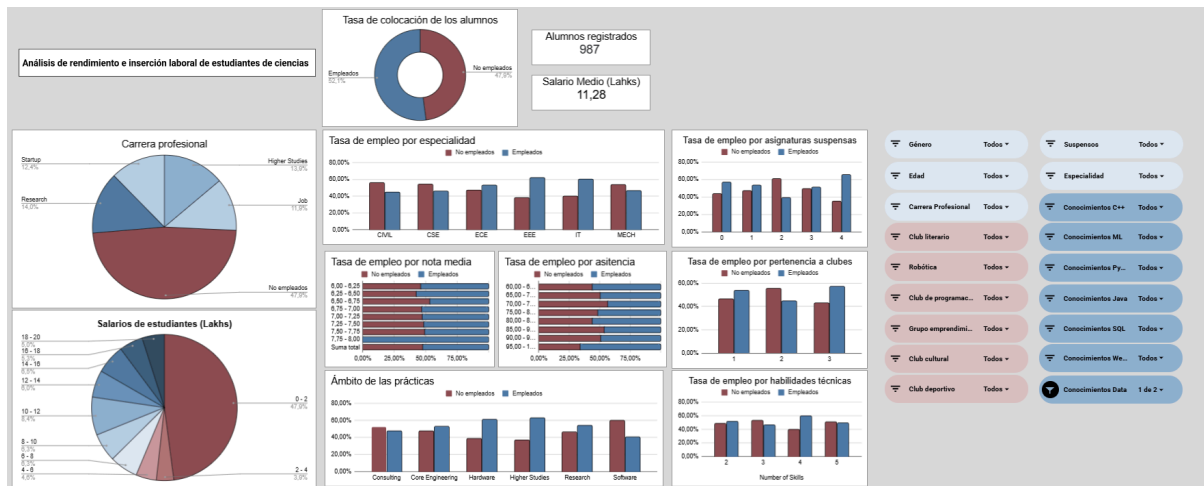
Conocimientos de SQL



Conocimientos de Web Development



Conocimientos de Data Science



Conclusiones

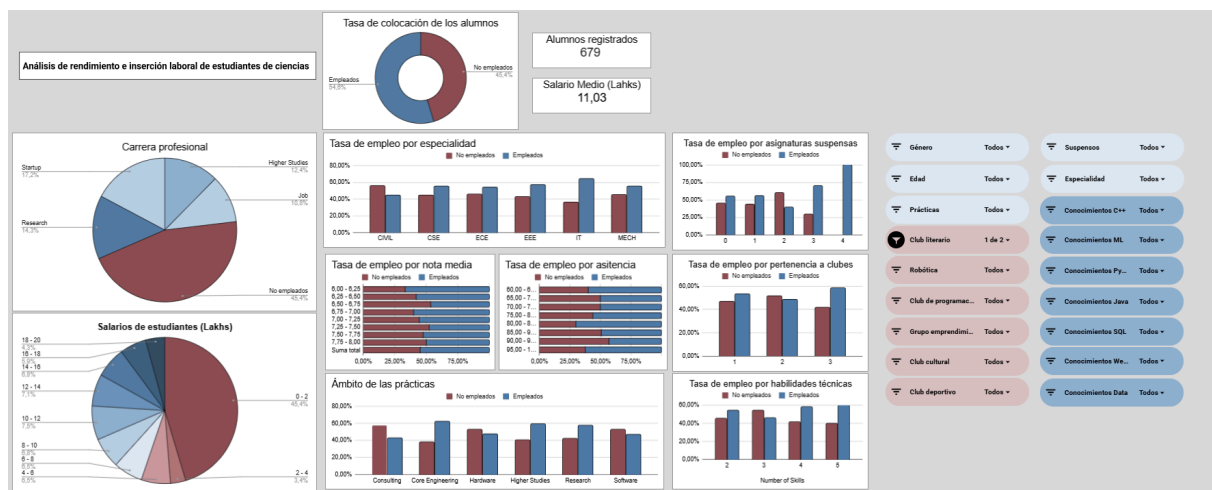
- Se observa como las 5 habilidades dan lugar a un porcentaje de empleabilidad superior a la tendencia general, confirmando lo que mostraba el análisis estadístico.
- Los salarios medios más altos los tienen aquellos alumnos que tienen conocimientos en Java, aunque son los que tienen conocimientos sobre Web Development los que tienen un mayor porcentaje de alumnos con salarios en el rango más alto.
- Atendiendo a la carrera profesional que tienen los estudiantes con los conocimientos anteriores, podemos observar carreras profesionales con perfiles diferenciados y, aunque se debe tener en cuenta que los alumnos pueden tener diferentes conocimientos, de acuerdo con esta información se podría clasificar el conocimiento con un tipo de perfil profesional
 - SQL: Emprendedor, ya que parecen preferir las startups.
 - Web Development: Investigador, ya que prefieren la investigación ('Research').
 - Java: Corporativo, ya que prefieren trabajos 'convencionales'.
 - Python: Perfiles más versátiles ya que tienen una preferencias similares.
 - Data Science: Académico, ya que tienen preferencia por estudios superiores.
- Los alumnos con estas habilidades/conocimientos que provienen de especialidades como EEE, ECE e IT tienen una mayor empleabilidad.

- A excepción de los alumnos con conocimientos de Web Development, el resto tiene una mayor empleabilidad tras haber cursado prácticas en Hardware, Estudios superiores o investigación.
- El resto de variables no tienen correlación o tienen una tendencia similar a la general.

Segmentación por pertenencia a clubes

Al igual que para analizar las relaciones cruzadas de las habilidades/conocimientos técnicos solo se han tenido en cuenta aquellas que tienen una mayor tasa de empleabilidad, en el caso de la pertenencia a clubes se va a repetir la estrategia, por lo que se comparará la pertenencia a los grupos de literatura y robótica frente a la tendencia general.

Pertenencia al grupo de literatura



Pertenencia al grupo de robótica



Conclusiones

- En ambos casos se puede observar como la empleabilidad es mayor que la media, por lo que confirma lo presentado en el análisis estadístico.
- En ambos casos, a pesar de tener mayor empleabilidad, el salario medio está por debajo de la media.
- Los alumnos que han participado tanto en el grupo de literatura como el de robótica cuyas prácticas han estado relacionadas con la consultoría, la ingeniería o investigación tienen mayor empleabilidad que la media.
- El resto de las estadísticas no parecen guardar mucha relación con la pertenencia a los clubes.

Resumen ejecutivo

Los datos mostrados en el análisis estadístico confirman rotundamente nuestra hipótesis principal.

✅ Las tres factores mencionados en la hipótesis inicial (especialidad, habilidades técnicas y clubes específicos) determinan la empleabilidad de los alumnos

✅ Existe un perfil de alto desempeño:

- Estudiante de EEE/ECE (IT queda fuera de la fórmula, como se muestra a continuación)
- Conocimientos de Java y SQL
- Participación en Robótica

- Prácticas en Investigación
- Perfil Investigador o Emprendedor.



🤔 **SORPRESA:** Los salarios para el grupo de alto desempeño son sustancialmente inferiores, aunque la muestra es menor y un 25% de esta no tiene ingresos.

📌 RECOMENDACIÓN ESTRATÉGICA:

- 🎯 **ESPECIALIZACIÓN TECNOLÓGICA:** Priorizar especialidades tecnológicas (EEE, ECE, IT) que demuestran mayor empleabilidad.
- 🖥️ **MAXIMIZAR HABILIDADES TÉCNICAS:** Adquirir competencias técnicas como lo son Java, SQL o Python, tiene un impacto notable en la empleabilidad.
- 🤝 **PARTICIPACIÓN EN GRUPOS ESTRATÉGICOS:** Incorporarse en clubes, como el de robótica, puede tener un impacto considerable en la empleabilidad, no solo por el conocimiento adquirido sino por las oportunidades que proporcionan las relaciones sociales.
- 🇮🇹 **SELECCIÓN INTELIGENTE DE PRÁCTICAS:** Enfocar las prácticas profesionales hacia dominios que están relacionados con nuevas tecnologías y el desarrollo, como la investigación, podría abrir puertas en el mundo laboral.

💡 **Consideración clave:** Si bien el rendimiento académico muestra menor correlación directa, mantiene importancia como requisito base. El verdadero diferenciador está en la **combinación estratégica** de estos elementos.